



Lista de Exercícios 4

- 4.1) Em economia, a distribuição Lognormal é frequentemente utilizada para modelar a renda de populações. Dizemos que $X \sim \text{Lognormal}(\mu, \sigma^2)$ se $Y = \ln(X)$ segue uma distribuição Normal(μ, σ^2). A densidade de X é dada por:

$$f(x; \mu, \sigma^2) = \frac{1}{x\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(\ln x - \mu)^2}{2\sigma^2} \right\}, \quad x > 0.$$

Seja $X_1, \dots, X_n$ uma amostra aleatória dessa população.

- (a) Escreva a função de verossimilhança $L(\mu, \sigma^2)$.
- (b) Escreva a função de log-verossimilhança $\ell(\mu, \sigma^2)$.
- (c) Derive o sistema de equações de score para o vetor de parâmetros $\theta = (\mu, \sigma^2)$.
- (d) Resolva o sistema e mostre que os estimadores de máxima verossimilhança são a média e a variância (viesada) dos logaritmos dos dados:

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n \ln(X_i) \quad \text{e} \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (\ln X_i - \hat{\mu})^2.$$

- 4.2) Considere uma amostra aleatória $X_1, \dots, X_n$ de uma população com distribuição Gama(α, β), com α e β desconhecidos. A função de densidade é dada por:

$$f(x; \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad x > 0, \alpha > 0, \beta > 0.$$

- (a) Escreva $L(\alpha, \beta)$.
- (b) Obtenha $\ell(\alpha, \beta)$.
- (c) Derive as equações de score para α e β (lembre que $\frac{d}{d\alpha} \ln \Gamma(\alpha) = \psi(\alpha)$).
- (d) Determine $\hat{\beta}$.
- (e) Explique por que $\hat{\alpha}$ não possui, em geral, uma expressão analítica simples.

- 4.3) Considere uma amostra aleatória $X_1, \dots, X_n$ de uma população com distribuição $U(\theta_1, \theta_2)$, com $\theta_1 < \theta_2$. A função densidade é dada por

$$f(x; \theta_1, \theta_2) = \frac{1}{\theta_2 - \theta_1}, \quad \theta_1 < x < \theta_2.$$

Os parâmetros θ_1 e θ_2 são desconhecidos.

- (a) Reescreva $f(x; \theta_1, \theta_2)$ usando função indicadora.
- (b) Escreva a função de verossimilhança $L(\theta_1, \theta_2)$ para uma amostra $x_1, \dots, x_n$.
- (c) Observe que a verossimilhança é positiva somente quando todos os valores observados pertencem ao intervalo (θ_1, θ_2) . Mostre que isso implica

$$\theta_1 < x_{(1)} \quad \text{e} \quad \theta_2 > x_{(n)},$$

onde $x_{(1)}$ e $x_{(n)}$ representam, respectivamente, o menor e o maior valor observado na amostra.

- (d) Para que a verossimilhança seja máxima, devemos escolher θ_1 e θ_2 de modo que o intervalo (θ_1, θ_2) seja o menor possível, mantendo todos os valores observados dentro dele. Explique por que isso implica escolher θ_1 e θ_2 a partir dos valores $x_{(1)}$ e $x_{(n)}$.
 - (e) Determine os estimadores de máxima verossimilhança $\hat{\theta}_1$ e $\hat{\theta}_2$.
 - (f) Explique por que, nesse caso, os estimadores de máxima verossimilhança não são obtidos anulando o gradiente da log-verossimilhança.
- 4.4) Considere uma amostra aleatória $X_1, \dots, X_n$ de uma população com distribuição $\text{Beta}(\alpha, \beta)$, com $\alpha > 0$ e $\beta > 0$. A função densidade é dada por

$$f(x; \alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad 0 < x < 1.$$

Os parâmetros α e β são desconhecidos. Considere a função digama definida por $\psi(t) = \frac{d}{dt} \log \Gamma(t)$.

- (a) Escreva a função de verossimilhança $L(\alpha, \beta)$.
- (b) Obtenha a função de log-verossimilhança $\ell(\alpha, \beta)$.
- (c) Obtenha as duas equações de score para α e β .
- (d) Explique por que o sistema de equações obtido não possui, em geral, uma solução analítica simples.
- (e) Explique por que a obtenção dos estimadores de máxima verossimilhança exige métodos numéricos.

Respostas:

- 4.1) (a) $L(\mu, \sigma^2) = (2\pi\sigma^2)^{-n/2} (\prod_{i=1}^n x_i)^{-1} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (\ln x_i - \mu)^2 \right\}$
(b) $\ell(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \sum_{i=1}^n \ln(x_i) - \frac{1}{2\sigma^2} \sum_{i=1}^n (\ln x_i - \mu)^2$
(c) $\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (\ln x_i - \mu)$
 $\frac{\partial \ell}{\partial (\sigma^2)} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (\ln x_i - \mu)^2$
- 4.2) (a) $L(\alpha, \beta) = \frac{\beta^{n\alpha}}{(\Gamma(\alpha))^n} (\prod_{i=1}^n x_i)^{\alpha-1} e^{-\beta \sum_{i=1}^n x_i}$
(b) $\ell(\alpha, \beta) = n\alpha \ln(\beta) - n \ln(\Gamma(\alpha)) + (\alpha - 1) \sum_{i=1}^n \ln(x_i) - \beta \sum_{i=1}^n x_i$
(c) $\frac{\partial \ell}{\partial \alpha} = n \ln(\beta) - n\psi(\alpha) + \sum_{i=1}^n \ln(x_i)$
 $\frac{\partial \ell}{\partial \beta} = \frac{n\alpha}{\beta} - \sum_{i=1}^n x_i$
(d) $\hat{\beta} = \frac{\hat{\alpha}}{\bar{X}}$
(e) Ao substituir $\hat{\beta}$ na equação de score para α ($\frac{\partial \ell}{\partial \alpha} = 0$), obtemos uma equação que envolve tanto a função digama $\psi(\alpha)$ quanto o logaritmo $\ln(\alpha)$. Essa é uma equação altamente não-linear. Devido à natureza dessas funções, é impossível isolar o $\hat{\alpha}$ algebricamente para obter uma solução fechada (analítica). O EMV $\hat{\alpha}$ é encontrado apenas por maximização numérica da função de log-verossimilhança.
- 4.3) (a) $f(x; \theta_1, \theta_2) = \frac{1}{\theta_2 - \theta_1} I_{[\theta_1, \theta_2]}(x)$
(b) $L(\theta_1, \theta_2) = \frac{1}{(\theta_2 - \theta_1)^n} \prod_{i=1}^n I_{[\theta_1, \theta_2]}(x_i)$
(c) O produto das indicadoras $\prod_{i=1}^n I_{[\theta_1, \theta_2]}(x_i)$ vale 1 se e somente se $\theta_1 \leq x_i \leq \theta_2$ para todo $i = 1, \dots, n$. Isso equivale a dizer que θ_1 deve ser menor ou igual ao menor valor da amostra ($x_{(1)}$) e θ_2 deve ser maior ou igual ao maior valor da amostra ($x_{(n)}$). Logo, $\theta_1 \leq x_{(1)}$ e $\theta_2 \geq x_{(n)}$.
(d) A função $L(\theta_1, \theta_2) = \frac{1}{(\theta_2 - \theta_1)^n}$ é estritamente decrescente em relação à amplitude $(\theta_2 - \theta_1)$. Portanto, para maximizar a verossimilhança, devemos minimizar essa amplitude. Respeitando as restrições $\theta_1 \leq x_{(1)}$ e $\theta_2 \geq x_{(n)}$, a menor amplitude ocorre quando escolhemos θ_1 o maior possível e θ_2 o menor possível dentro desse intervalo válido.
(e) Deste raciocínio direto, concluímos que os estimadores de máxima verossimilhança são:

$$\hat{\theta}_1 = x_{(1)} \quad \text{e} \quad \hat{\theta}_2 = x_{(n)}$$

(f) O suporte da distribuição (os limites onde $f(x) > 0$) depende diretamente dos parâmetros a serem estimados (θ_1 e θ_2). Com isso, as chamadas Condições de Regularidade de Cramér falham. A função de verossimilhança não é diferenciável nos pontos de máximo, e este máximo ocorre na fronteira do espaço paramétrico (determinada pela própria amostra), inviabilizando o uso de derivadas (gradiente zero) para encontrar o estimador.

- 4.4) (a) $L(\alpha, \beta) = \left(\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \right)^n (\prod_{i=1}^n x_i)^{\alpha-1} (\prod_{i=1}^n (1-x_i))^{\beta-1}$
- (b) $\ell(\alpha, \beta) = n \ln \Gamma(\alpha + \beta) - n \ln \Gamma(\alpha) - n \ln \Gamma(\beta) + (\alpha - 1) \sum_{i=1}^n \ln(x_i) + (\beta - 1) \sum_{i=1}^n \ln(1 - x_i)$
- (c) $\frac{\partial \ell}{\partial \alpha} = n\psi(\alpha + \beta) - n\psi(\alpha) + \sum_{i=1}^n \ln(x_i) = 0$
 $\frac{\partial \ell}{\partial \beta} = n\psi(\alpha + \beta) - n\psi(\beta) + \sum_{i=1}^n \ln(1 - x_i) = 0$
- (d) As equações geradas pelas derivadas parciais não possuem uma solução analítica simples porque combinam termos lineares/aditivos das amostras com a função digama (ψ), que é uma função especial e não-linear. Devido à presença simultânea de $\psi(\alpha + \beta)$, $\psi(\alpha)$ e $\psi(\beta)$, é impossível encontrar uma manipulação algébrica que isole os parâmetros α e β .
- (e) Como não é possível isolar α e β explicitamente a partir das equações de score ($\frac{\partial \ell}{\partial \alpha} = 0$ e $\frac{\partial \ell}{\partial \beta} = 0$), devemos recorrer a algoritmos de aproximação iterativa (como os métodos de Newton-Raphson, Scoring de Fisher ou métodos de quase-Newton). Esses métodos numéricos partem de chutes iniciais e navegam pela superfície da log-verossimilhança até encontrarem o ponto máximo de forma aproximada.